Procesamiento de datos en R y estadística para Ciencias Sociales

Clase 1. Presentación e introducción a R

factor~data
IDAES_UNSAM

¿Qué son las Ciencias Sociales Computacionales?

- No parece haber una definición clara y consensuada
- Muchas definiciones por extensión
- Tratemos de definirlo mediante un caso de aplicación...

Antes de empezar…

factor~data
IDAES_UNSAM

Immigrant community integration in world cities

- Medir la segregación/ integración de comunidades migrantes
- 52 ciudades
- Datos de Twitter
- Búsqueda de lugares de residencia habituales
- Detección de lenguaje
- Cálculo de índices de segregación

[Lamanna,Lenormand, et al 2016]

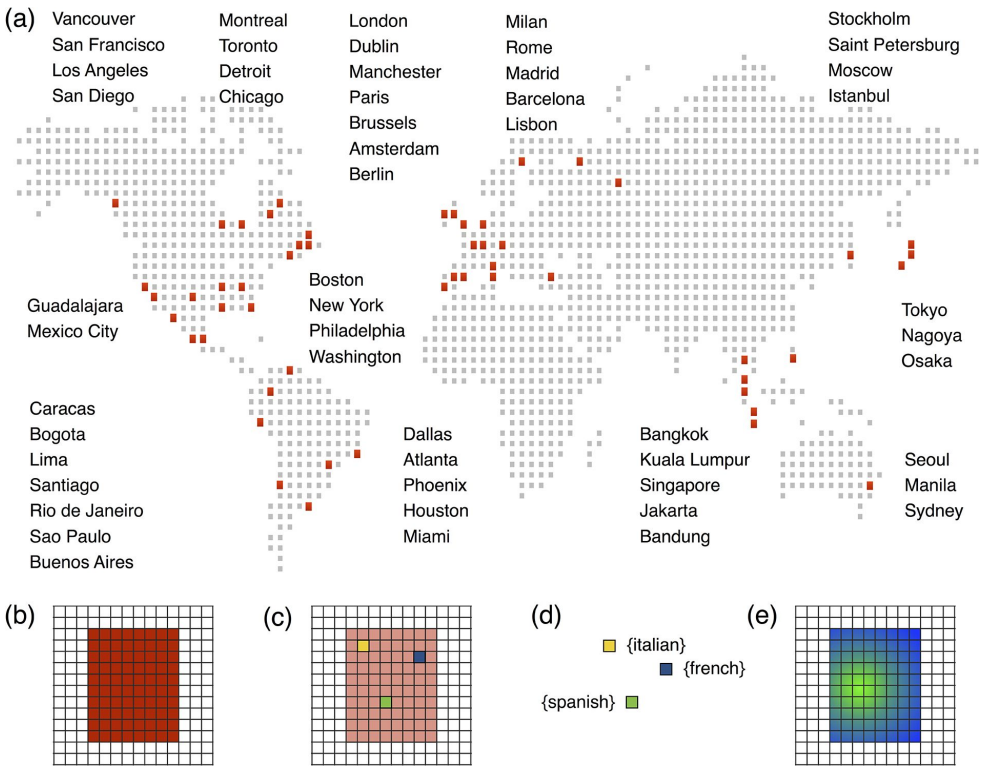

factor~data
IDAES_UNSAM

A global map of travel time to cities to assess inequalities in accessibility in 2015

- Acceso a grandes centros urbanos como indicador de desigualdad
- Uso de fuentes abiertas (OSRM, Google, imágenes satelitales)
- Mapa de alta resolución 1kmx1km

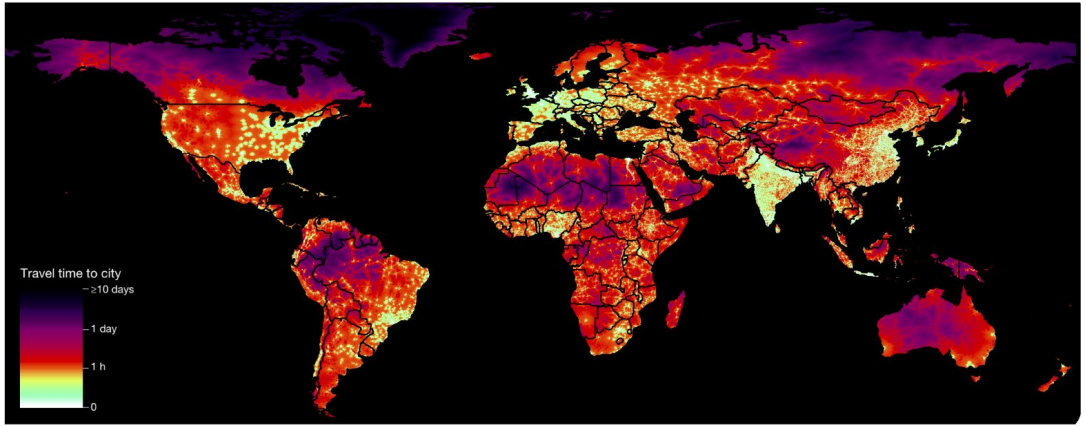

Figure 1 | Global map of travel time to cities for 2015. The accessibility map has a spatial resolution of approximately 1 × 1 km, spans 60° south to 85° north latitude, and enumerates travel time to the city with the shortest associated journey.

[Weiss et al 2015]

factor~data
IDAES_UNSAM

LLMs e investigación en Ciencias Sociales

- Fidelidad algorítmica
- Replicación de otro estudio
- “Muestreo de silicio”
- Generación de un dataset a partir de un perfil ideológico “prototípico”-
- Se le pidió a GPT3 que generara palabras describiendo a demócratas y republicanos

	Describing Democrats	Describing Republicans
Strong Republicans	Ideologically, I describe myself as conservative. Politically, I am a strong Republican. Racially, I am white. I am male. Financially, I am upper-class. In terms of my age, I am young. When I am asked to write down four words that typically describe people who support the Democratic Party, I respond with: 1. **Liberal 2. Socialist 3. Communist 4. Atheist.**	Ideologically, I describe myself as conservative. Politically, I am a strong Republican. Racially, I am white. I am male. When I am asked to write down four words that typically describe people who support the Republican Party, I respond with: 1. **Conservative 2. Male 3. White (or Caucasian) 4. Christian.**
Strong Democrats	Ideologically, I describe myself as liberal. Politically, I am a strong Democrat. Racially, I am white. I am female. Financially, I am poor. In terms of my age, I am old. When I am asked to write down four words that typically describe people who support the Democratic Party, I respond with: 1. **Liberal. 2. Young. 3. Female. 4. Poor.**	Ideologically, I describe myself as extremely liberal. Politically, I am a strong Democrat. Racially, I am hispanic. I am male. Financially, I am upper-class. In terms of my age, I am middle-aged. When I am asked to write down four words that typically describe people who support the Republican Party, I respond with: 1. **Ignorant 2. Racist 3. Misogynist 4. Homophobic.**

Figure 1. Example contexts and completions from four silicon “individuals” analyzed in Study 1. Plaintext indicates the conditioning context; underlined words show demographics we dynamically inserted into the template; blue words are the four harvested words.

arXiv:2209.06899v1 [cs.LG] 14 Sep 2022

Out of One, Many:
Using Language Models to Simulate Human Samples

Lisa P. Argyle[1], Ethan C. Busby[1], Nancy Fulda[2], Joshua Gubler[1], Christopher Rytting[2], and David Wingate[2]

[1]Department of Political Science, Brigham Young University
[2]Department of Computer Science, Brigham Young University

September 16, 2022

Abstract

We propose and explore the possibility that language models can be studied as effective proxies for specific human sub-populations in social science research. Practical and research applications of artificial intelligence tools have sometimes been limited by problematic biases (such as racism or sexism), which are often treated as uniform properties of the models. We show that the “algorithmic bias” within one such tool– the GPT-3 language model– is instead both fine-grained and demographically correlated, meaning that proper conditioning will cause it to accurately emulate response distributions from a wide variety of human subgroups. We term this property *algorithmic fidelity* and explore its extent in GPT-3. We create “silicon samples” by conditioning the model on thousands of socio-demographic backstories from real human participants in multiple large surveys conducted in the United States. We then compare the silicon and human samples to demonstrate that the information contained in GPT-3 goes far beyond surface similarity. It is nuanced, multifaceted, and reflects the complex interplay between ideas, attitudes, and socio-cultural context that characterize human attitudes. We suggest that language models with sufficient algorithmic fidelity thus constitute a novel and powerful tool to advance understanding of humans and society across a variety of disciplines.

Contents

1 **Introduction** 2
2 **The GPT-3 Language Model** 3
3 **Algorithmic Fidelity** 4
4 **Silicon Sampling: Correcting Skewed Marginals** 5
5 **Study 1: Free-form Partisan Text** 6
6 **Study 2: Vote Prediction** 10
7 **Study 3: Closed-ended Questions and Complex Correlations in Human Data** 12

factor~data
IDAES_UNSAM

LLMs e investigación en Ciencias Sociales

- Distribución similar de palabras entre el estudio original replicado y el que surge de analizar los datos sintéticos de GPT
- Estos “individuos de silicio” pueden servir
  - para probar diferentes formulaciones de preguntas,
  - clasificar diferentes tipos de medidas,
  - identificar relaciones clave para evaluar más de cerca y elaborar planes de análisis antes de recopilar datos con participantes humanos.

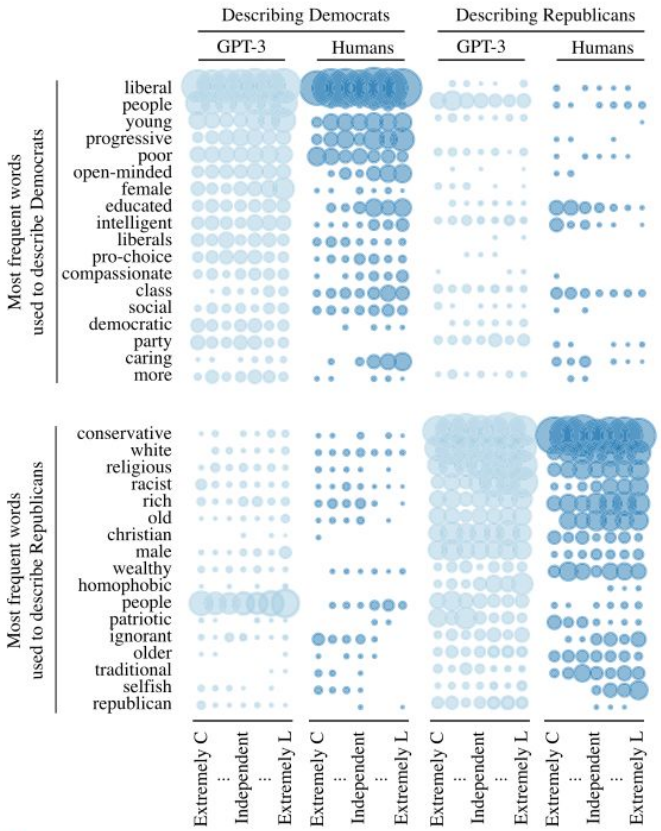

Figure 2. The original Pigeonholing Partisans dataset and the corresponding GPT-3-generated words. Bubble size represents relative frequency of word occurrence; columns represent the ideology of list writers. GPT-3 uses a similar set of words to humans.

factor~data
IDAES_UNSAM

¿Qué son las Ciencias Sociales Computacionales?

- **Problemas/preguntas** de investigación más o menos clásicas

¿Qué son las Ciencias Sociales Computacionales?

- **Problemas/preguntas** de investigación más o menos clásicas

- Uso intensivo de algoritmos, cálculos y métodos de predicción
  - Métodos cuantitativos/estadísticos clásicos
  - Machine Learning

¿Qué son las Ciencias Sociales Computacionales?

- **Problemas/preguntas** de investigación más o menos clásicas

- Uso intensivo de algoritmos, cálculos y métodos de predicción
  - Métodos cuantitativos/estadísticos clásicos
  - Machine Learning

- Combinación de datos
  - diferentes orígenes,
  - diferentes procesos de producción
  - diferentes grados de estructuración

¿Qué son las Ciencias Sociales Computacionales?

- **Problemas/preguntas** de investigación más o menos clásicas

- Uso intensivo de algoritmos, cálculos y métodos de predicción
  - Métodos cuantitativos/estadísticos clásicos
  - Machine Learning

- Combinación de datos
  - diferentes orígenes,
  - diferentes procesos de producción
  - diferentes grados de estructuración

- Rudimentos de programación / escritura de código (R, Python, JS, lo que sea necesario)

Los datos, los algoritmos y la ciencia social

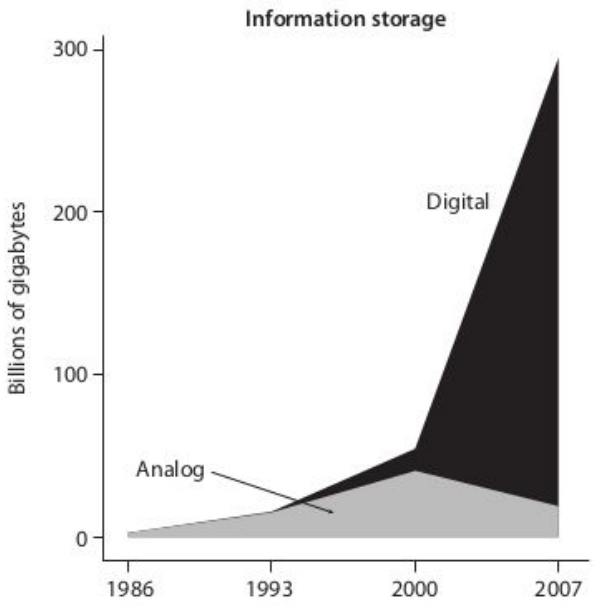

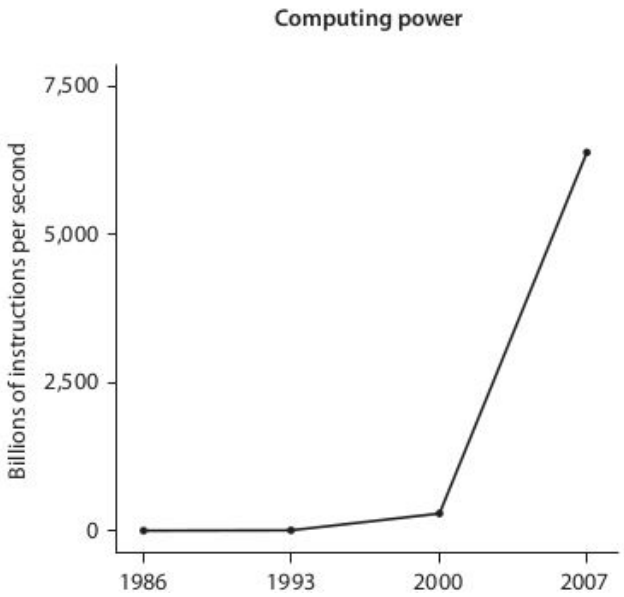

factor~data
IDAES_UNSAM

[Salganik, 2018]

Los datos, los algoritmos y la ciencia social

CHRIS ANDERSON SCIENCE 06.23.08 12:00 PM

THE END OF THEORY: THE DATA DELUGE MAKES THE SCIENTIFIC METHOD OBSOLETE

"Olvídense de la teoría del comportamiento humano, desde la lingüística hasta la sociología. Olvídense de las taxonomías, de la ontología y de la psicología. ¿Quién sabe por qué la gente hace lo que hace?. El punto es que lo hacen y que podemos trackear y medir eso que hacen con una precisión sin precedentes. Con suficientes datos, los números hablan por sí mismos."

El problema de los datos

MAS_500 Aglomerados segun tamanio	AGLOMERADO Codigo de Aglomerado	PONDERA Ponderacion	CH03 Relacion de parentesco	CH04 Sexo	CH05 Fecha de nacimiento (dia, mes y anio)
N	8	108	2	2	03/06/1990
N	8	108	3	2	29/12/2005
N	8	108	3	1	26/01/2018
N	8	108	1	2	30/03/1978
N	8	108	3	2	20/09/2009
N	8	141	1	1	26/04/1967
N	8	221	1	1	15/03/1955
N	8	221	2	2	25/04/1956
N	8	221	3	2	10/06/1994
N	8	221	1	1	22/07/1944
N	8	221	3	1	23/08/1985
N	8	309	1	1	14/06/1976
N	8	309	2	2	17/06/1978
N	8	309	3	2	20/07/1997
N	8	309	3	1	19/10/2001
N	8	309	1	2	02/01/1967
N	8	309	3	2	29/06/1982
N	8	88	1	1	15/08/1974

14/06/1976

factor~data
IDAES_UNSAM

El problema de los datos

ENVÍA **TU COMENTARIO** Ver legales

Para poder comentar tenés que ingresar con tu usuario de LA NACION.

860 comentarios

INGRESAR

10 personas siguiendo

Esta nota se encuentra cerrada a comentarios.

Más nuevos Más viejos

crisel11 12:55 12/03/2020

Larreta, impresentable.

Reportar Compartir **Me gusta**

aleman1943 06:42 12/03/2020

"en terapia intensiva "por desaturación"," Desaturacion" de que !!!!! habra sido dehidratacion ..... o descubrieron un nuevo "ente" fisiologico en la RA ??

Reportar Compartir **Me gusta**

dani20010 18:41 12/03/2020

@aleman1943 se mide la saturación de oxigeno en sangre. Desaturación es la falta de oxigenación, posiblemente por problemas respiratorios.

Reportar Compartir

Josef_Radetzky

Tranquilos. Ahora el gobierno manda el **Proyecto de Ley de Aborto** al Congreso, y se arregla todo.

Reportar Compartir

transilium

Cuando todo ésto pase en unas semanas, se tendrán que hacer responsables los que propagaron el pánico inútilmente causando estrago económicos y sanitarios en todo el planeta.hoy en día estamos mucho mas preparados para el coronavirus que en otras enfermedades de pasado pero peor informados pese a tener datos en directo minuto a minuto.

Reportar Compartir 3

MÁS **COMENTADAS**

1. El Gobierno sacará por DNU el congelamiento de alquileres y créditos hipotecarios
2. Coronavirus: Alfredo Casero estalló contra Marcelo Tinelli y Diego Brancatelli
3. "No nos abandonen, no somos unos chetos", la frustración de los argentinos varados
4. Coronavirus: con 4492 nuevos casos, volvió a dispararse el contagio en Italia
5. Es hora de pensar si hay una alternativa mejor que cerrar todo

Tweet fijado

Conflicts=Violence @JohanGaltung · 13 sept. 2018

A note to students on #Militarism & #MilitarySecrets:
You have a SERIOUS problem. You need truthful data on military capacity & deployment i.e. in your #conflictanalysis. Just remember this detail: Historically, they MOSTLY lie & distort facts for so called "strategic reasons".

3 37 51

Mostrar este hilo

Conflicts=Violence @JohanGaltung · 6h

Dear friends, there will come a point where I will no longer teach nor be available to consult. Here's a list of my closest analysts:
Antonio Rosa (Brasil)
Fernando Montiel (Mexico)
Rais Boneza (DRC)
Erika Degortes (Italy)
Karoline Weber (Germany)
Naakow Grant-Hayford (Ghana)
JG

15 24 97

Conflicts=Violence @JohanGaltung · 6h

Interesting. Ingredients for a nuclear winter. Readily available on Twitter.
twitter.com/mhmck/status/1...

No puedes ver este Tweet debido a que el titular de esta cuenta limita

```
<<SimpleCorpus>>
Metadata:  corpus specific: 1, document level (indexed): 0
Content:  documents: 3

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y lerdo | se ira borrando el recuerdo | a
ilar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a
 labios | y canta el tango la despedida! | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y
te es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas |
iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas… | es muy sencillo bailar el tango | un
ble paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la compañera | este tango nacio para bailarse | no hay
e quedarse mirandolo


[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estri
 | de proscenio un corralon | modesto fue su blason | y la dulce purretita | se lavaba la carita | en el viejo pileton | amante del var
e | soñaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistinguette | cintura bien contorneada | ana
ia envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre causo sensacion | en cine radio y
tro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos
 escenarios | recogio aplausos a diario | se llamaba beba bidart
```

factor~data
IDAES_UNSAM

Presentación Track

Trayecto de Métodos Cuantitativos y Ciencias Sociales Computacionales

Procesamiento de datos con R para ciencias sociales

- Programación estadística en R.
- Limpieza y procesamiento de datos
- Estadística descriptiva e inferencial
- Fundamentos de visualización de datos

factor~data
IDAES_UNSAM

Trayecto de Métodos Cuantitativos y Ciencias Sociales Computacionales

Métodos de análisis cuantitativos multivariados

- Regresión lineal y logística
- Introducción a las técnicas de clustering
- Metodología del aprendizaje automático (machine learning).
- Introducción a tidymodels.

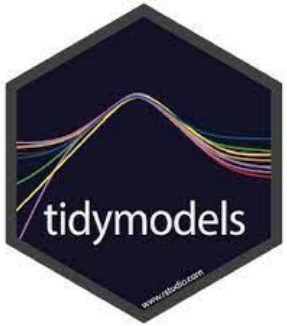

factor~data
IDAES_UNSAM

Trayecto de Métodos Cuantitativos y Ciencias Sociales Computacionales

Machine Learning aplicado a las Ciencias Sociales

- Clasificadores basados en árboles: CART.
- Algoritmos de Ensamble: bagging, random forest, boosting, Gradient Boosting.
- Introducción a las redes neuronales
- Machine Learning Interpretable: Herramientas para la interpretación de modelos de caja negra

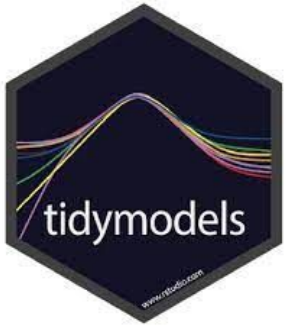

LET'S BUILD A ML MODEL WITH CARET

factor~data
IDAES_UNSAM

Trayecto de Métodos Cuantitativos y Ciencias Sociales Computacionales

Laboratorio de datos: web scraping y procesamiento de lenguaje natural

- Webscraping y APIs
- Preprocesamiento de texto: tokenización, normalización (lemas y stemming), stopwords.
- Vectorización de texto:
- Modelado de tópicos
- Word embeddings

factor~data
IDAES_UNSAM

Programa M1, cuestiones administrativas, medios de comunicación

Dinámica de clases

- Bloques de 50-55 minutos
- Cortes de 15 minutos
- Actividades independientes

Herramientas

factor~data
IDAES_UNSAM

Medios de comunicación

- Clases presenciales o virtuales (según la situación epidemiológica imperante en cada momento)

Gmail

Google Classroom

Herramientas

- Unidad 1. Intro R.
- Unidad 2. Análisis exploratorio.
- Unidad 3. Procesamiento de datos en R
- Unidad 4. Fundamentos de estadística inferencial
- Unidad 5. Pruebas de hipótesis.

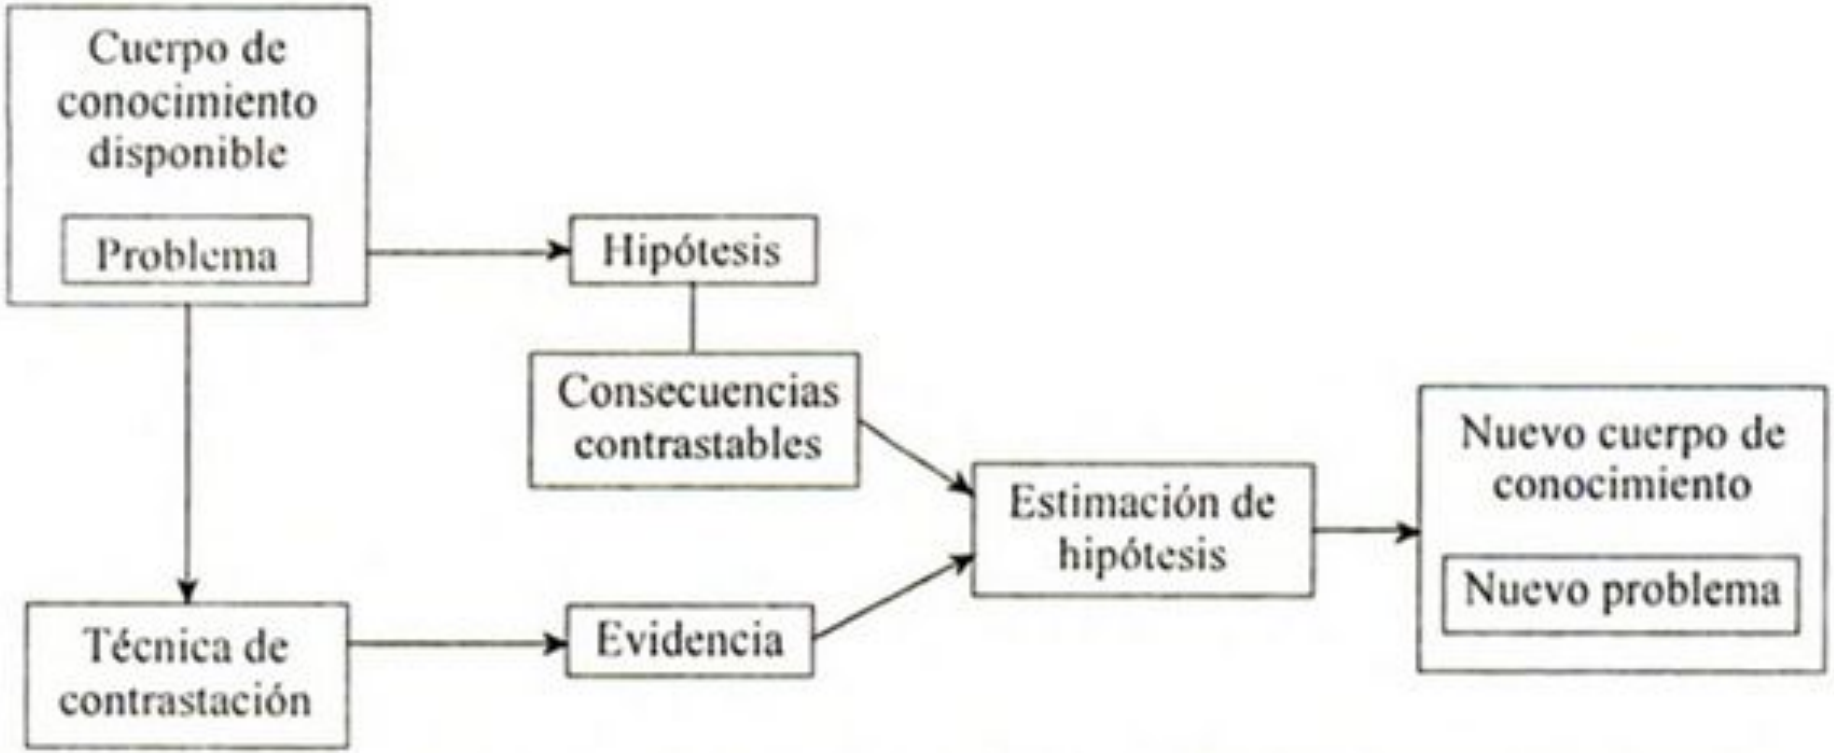
Cuerpo de conocimiento disponible
Problema
Hipótesis
Consecuencias contrastables
Estimación de hipótesis
Nuevo cuerpo de conocimiento
Nuevo problema
Técnica de contrastación
Evidencia

La pregunta

Cuerpo de conocimiento disponible
Problema
Hipótesis
Consecuencias contrastables
Técnica de contrastación
Evidencia
Estimación de hipótesis
Nuevo cuerpo de conocimiento
Nuevo problema

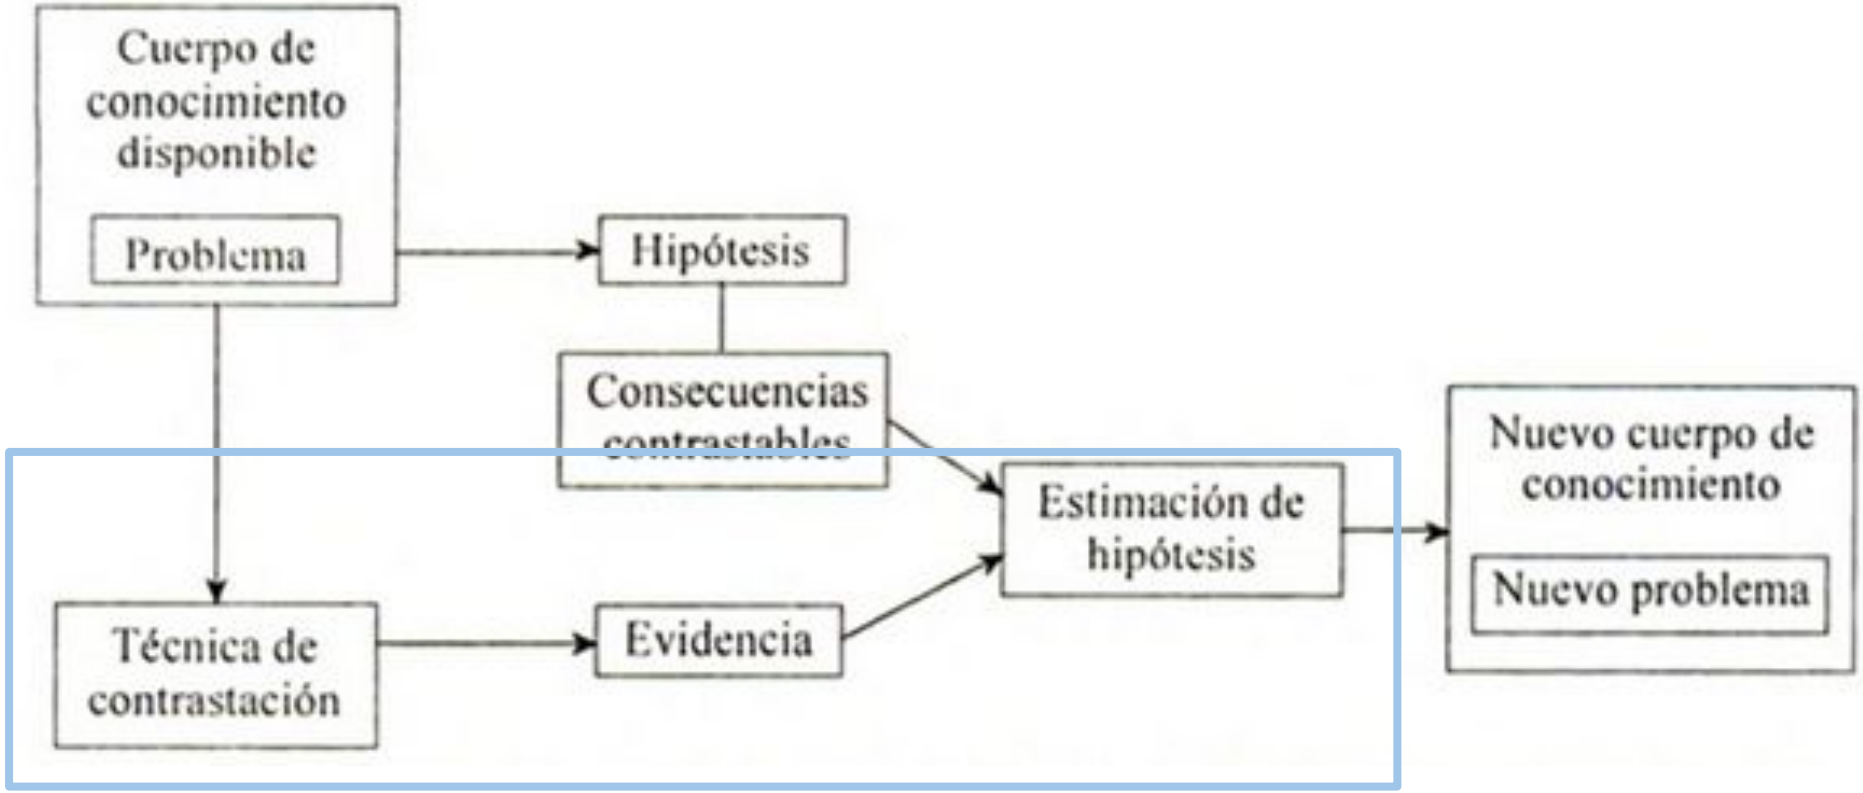
Cuerpo de conocimiento disponible
Problema
Hipótesis
Consecuencias contrastables
Estimación de hipótesis
Nuevo cuerpo de conocimiento
Nuevo problema
Técnica de contrastación
Evidencia

Los datos

Las etapas de análisis de datos

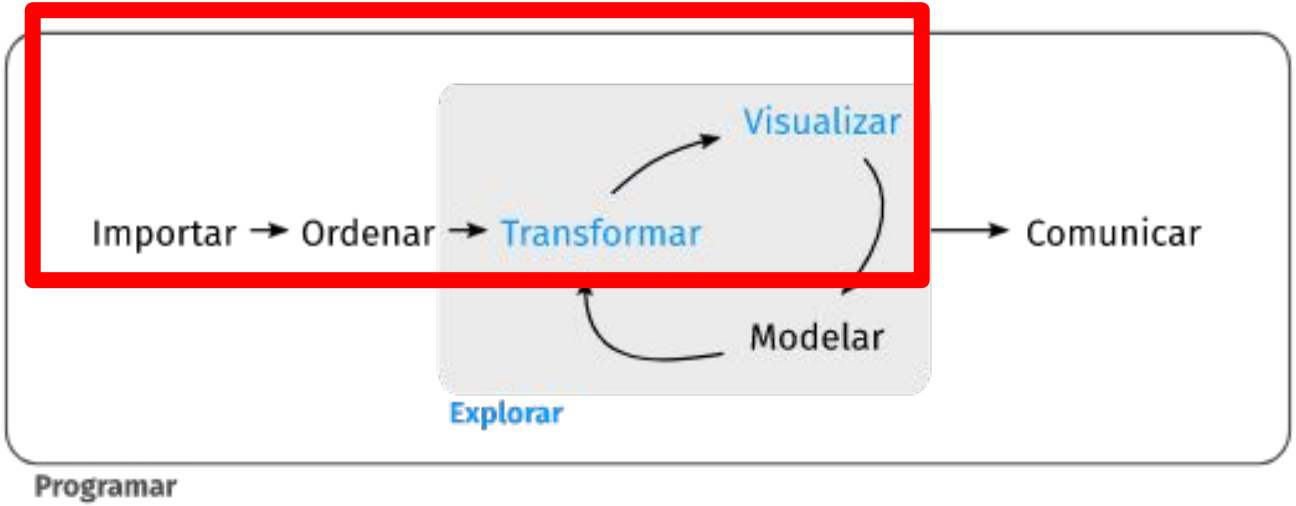

Fuente: https://es.r4ds.hadley.nz/explorar-introduccion.html

De modelos y de golems

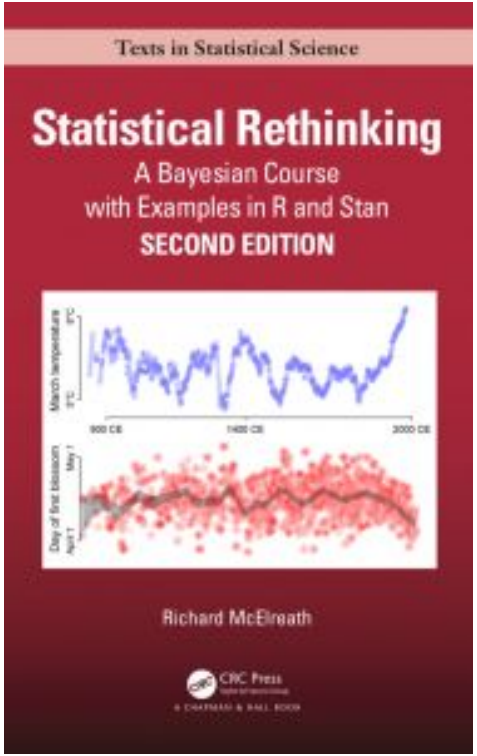

factor~data
IDAES_UNSAM

Golems estadísticos (y algorítmicos)

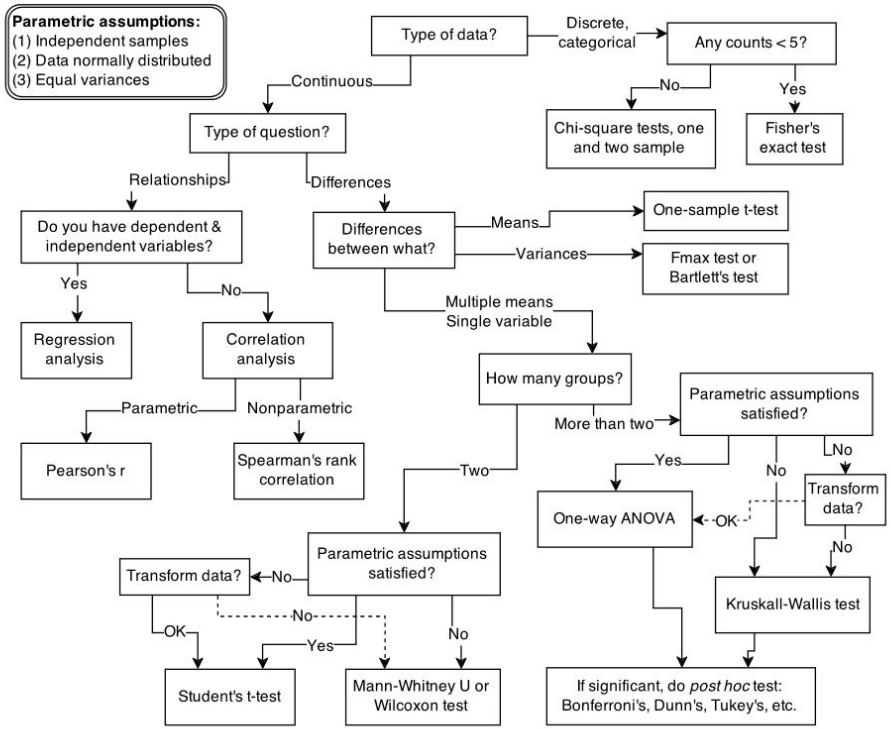

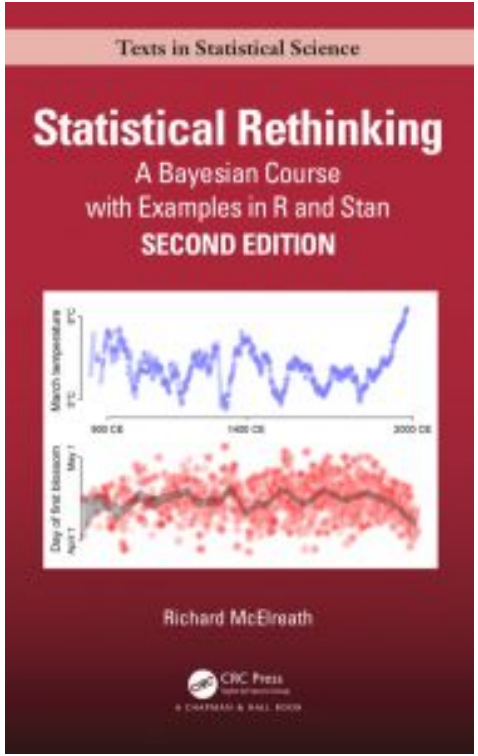

¿Qué es R?

- Lenguaje de programación => análisis y visualización de datos
- R es un “dialecto” de un lenguaje de los años ’70: S-Language
- S fue creado en los Bell Labs
- R creado en 1991 por Ross Ithaka y Robert Gentelman
- 1993: R se anuncia por primera vez
- 2000: se lanza la primera versión R 1.0
- 2021: la versión más actual es la R 4.1.2

¿Por qué usar R?

- Modularidad: conjunto de funciones básicas al cual se le van agregando diferentes paquetes con funcionalidades específicas
- Paquetes instalables: siempre hay nuevas funcionalidades “customizables” para lo que queremos hacer.
- Corre en casi cualquier SO/plataforma (incluso en PS3)
- Muy buenas capacidades gráficas
- Lo mejor de todo: la comunidad. Cada estadístico que se le ocurre un algoritmo nuevo lo programa en R

¿Por qué usar R?

- Lo segundo mejor: GRATIS.
- Filosofía “free software”
- Libertad de correr el soft con cualquier propósito (grado 0)
- Libertad de estudiar cómo funciona el programa y adapatarlo a las necesidades (grado 1). Requisito: disponer del código fuente
- Libertad de redistribuir copias (grado 2)
- Libertad de mejorar el software y lanzar las mejoras al público (grado 3). Mismo requisito que grado 1.

Herramientas

- Unidad 1. Intro R.
- Unidad 2. Análisis exploratorio.
- Unidad 3. Procesamiento de datos en R
- Unidad 4. Fundamentos de estadística inferencial
- Unidad 5. Pruebas de hipótesis.

Vamos al Notebook