


Métodos de análisis cuantitativos multivariados

Clase 5. Métricas de evaluación para regresión logística


Introducción

- La regresión logística devuelve una probabilidad: $p(y=1|X)$
- A veces necesitamos una categoría (Sí-No; Obrero-No obrero; Ocupado-No ocupado). Ahí hay que fijar un umbral.
- Otras veces lo que interesa es la probabilidad en sí: cuánto desplaza cada variable a p .
- Cuál de los dos casos es lo define la pregunta de investigación, no los datos.



De una probabilidad a una categoría

- Podemos representar en la línea las probabilidades predichas y con el color la clase observada.



De una probabilidad a una categoría


- Regresión logística (pero vale para otros)
- La predicción “nativa” de una regresión logística es una probabilidad
- Se aplica una regla de decisión para asignarle un valor positivo o negativo

Si $p(y=1 | X) > 0.5 \Rightarrow$ el caso es positivo

Si $p(y=1 | X) \leq 0.5 \Rightarrow$ el caso es negativo


De una probabilidad a una categoría

- Todo caso que tenga una probabilidad predicha mayor a 0.5 va a ser considerado un caso “positivo” (en nuestra predicción).




De una probabilidad a una categoría

- Esto nos va a permitir definir una herramienta clave: la matriz de confusión.



De una probabilidad a una categoría

- Esto nos va a permitir definir una herramienta clave: la matriz de confusión.



	Positivo (pred)	Negativo (pred)	Total
Positivo (obs)	11	0	11
Negativo (obs)	5	14	19
Total	16	14	30

Matriz de confusión

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

También llamada **recall**

Evaluando regresión logística: F1

$$F_1 = 2 * \frac{precision * recall}{precision + recall}$$

- Es la media armónica entre precision y recall
- Si cualquiera de las dos es baja, F1 es baja
- A diferencia de la media aritmética, no se deja compensar

Precision	Recall	Media aritmética	F1
0.90	0.10	0.50	0.18
0.50	0.50	0.50	0.50

Misma media aritmética, F1 muy distinto: la armónica distingue el caso balanceado del que sólo parece bueno en una de las dos.

Evaluando regresión logística: F-beta

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}.$$

- F1 da igual peso a precision y recall
- F-beta permite cambiar ese peso con el parámetro beta
- Beta pesa el recall en relación a la precision

En la fórmula

beta $\rightarrow \infty$ F-beta $\rightarrow$ recall

beta $\rightarrow 0$ F-beta $\rightarrow$ precision

En la práctica


F2 prioriza recall (caro perder un positivo)

F0.5 prioriza precision (caro un falso positivo)

El peso lo fija la estructura de costos del problema, no el dato.

De una probabilidad a una categoría

- Variando el umbral (0.5), puedo hacer hacer variar las métricas basadas en la matriz de confusión. ¿Cuál sería un buen modelo base para comparar?




Base (nulo => predecir siempre negativo)
Accuracy = 19/30 = 0.63

Umbral = 0.5
Accuracy = 0.83
Precision = 0.69
Recall = 1.0

	Positivo (pred)	Negativo (pred)	Total
Positivo (obs)	11	0	11
Negativo (obs)	5	14	19
Total	16	14	30

De una probabilidad a una categoría

- Variando el umbral (0.5), puedo hacer hacer variar las métricas basadas en la matriz de confusión




	Positivo (pred)	Negativo (pred)	Total
Positivo (obs)	7	4	11
Negativo (obs)	0	19	19
Total	7	23	30

Umbral = 0.76
Accuracy = 0.87
Precision = 1.0
Recall = 0.64

De una probabilidad a una categoría

- Variando el umbral (0.5), puedo hacer hacer variar las métricas basadas en la matriz de confusión



Umbral = 0.13


Accuracy = ?

Precision = ?

Recall = ?

	Positivo (pred)	Negativo (pred)	Total
Positivo (obs)	11	0	11
Negativo (obs)	15	4	19
Total	26	4	30

Evaluando regresión logística




- Curva ROC y métrica AUC: cuantificar la performance agregada de diferentes clasificadores para todos los umbrales posibles
 - Eje X: tasa de falsos positivos (1 - especificidad)
 - Eje Y: tasa de verdaderos positivos (sensibilidad)
- Buscamos curvas que suban rápido a la izquierda
- $AUC = P(\text{la probabilidad predicha de un positivo al azar} > \text{la de un negativo al azar})$


Evaluando regresión logística

True positive rate (o recall)

$$\frac{tp}{tp + fn}$$




False positive rate



$$\frac{FP}{FP + TN}$$

Evaluando regresión logística

rf y gbm empatan en 0.94; nb queda en 0.83. ¿Cuál es mejor?



- El AUC agrega sobre todos los umbrales, incluidos los que nunca vamos a usar: conviene mirar la región de la curva del punto de operación real
- El AUC es invariante a cualquier transformación monótona de las probabilidades: dos modelos con el mismo AUC pueden estar calibrados muy distinto
- Un empate en AUC no es un empate en utilidad

Para responder bien hacen falta métricas que miren la probabilidad, no sólo el orden.

Volvamos a la pregunta

“¿Cómo podemos comparar una variable discreta (la y observada) con una continua (las probabilidades del modelo)?”

Lo observado

$y \in \{0, 1\}$ — discreta

Lo predicho

$\hat{p} \in (0, 1)$ — continua

En ningún modelo comparamos y con “lo mismo”: siempre comparamos y contra $E[Y|X]$


Regresión lineal: $E[Y|X] = \mu$

Regresión logística: $E[Y|X] = p$

El residuo $y - \hat{p}$ tiene esperanza cero por construcción. La comparación no sólo es válida: es la que el modelo ya hace al estimarse.

Dos caminos a partir de $\hat{p}$

El modelo devuelve una probabilidad. Umbralizar es una opción, no un paso obligatorio.


$$\hat{p} = p(y=1|X)$$

A. ¿Hay una decisión que tomar?

Asignar, seleccionar, focalizar, intervenir → hace falta un umbral

Matriz de confusión · accuracy · precision · recall · F1 · ROC-AUC

B. ¿Interesa la probabilidad en sí?

Explicar, describir, cuantificar efectos → no hace falta umbral

Log-loss · Brier · deviance · pseudo- R^2

Cuál corresponde lo define la pregunta de investigación, no los datos: la misma encuesta sirve para las dos cosas.

Log-loss (entropía cruzada)

Para cada caso sobrevive un solo término de la fórmula. **La pérdida del caso es menos el logaritmo de la probabilidad que el modelo le había asignado a lo que pasó.**

$$\text{log-loss} = - (1/n) \sum [y_i \cdot \log(\hat{p}_i) + (1-y_i) \cdot \log(1-\hat{p}_i)] \quad \text{si } y=1 \text{ queda } -\log(\hat{p}) \quad \text{si } y=0 \text{ queda } -\log(1-\hat{p})$$


y observado	$\hat{p}$ prob. de que y=1	Prob. que el modelo le asignó a lo que pasó	pérdida = $-\log(\text{esa prob.})$
1	0.90	0.90	$-\log(0.90) = 0.105$
1	0.60	0.60	$-\log(0.60) = 0.511$
0	0.20	0.80 (= 1 - 0.20)	$-\log(0.80) = 0.223$
0	0.45	0.55 (= 1 - 0.45)	$-\log(0.55) = 0.598$
1	0.10	0.10	$-\log(0.10) = 2.303$
		media de la columna	0.748

Leer la fila roja: el modelo le daba 10% de chance a un caso que resultó positivo. Ese único error aporta 2.303 de los 3.74 de pérdida total, el 62%. El logaritmo es lo que castiga equivocarse con confianza.

La misma fórmula, en el otro rol

Antes los coeficientes estaban fijos y calculábamos la pérdida. **Acá al revés: los coeficientes son la incógnita y la pérdida es el criterio para elegirlos.**

Tomemos el modelo más simple posible: el mismo $\hat{p}$ para los 30 casos del ejemplo (11 positivos). ¿Qué valor conviene elegir?



$\hat{p}$ elegido	log-loss
0.20	0.731
0.30	0.667
0.367 = 11/30	0.657
0.45	0.671
0.60	0.768

El mínimo cae exactamente en la proporción observada. Eso no es casualidad: es el estimador de máxima verosimilitud.

Eso es glm(): busca los coeficientes que minimizan esta misma log-loss, sólo que sobre un modelo con predictores y con un algoritmo en lugar de una grilla.

Brier: el ECM aplicado a probabilidades

Brier = $(1/n) \sum (y_i - \hat{p}_i)^2$ ← la misma fórmula del ECM de la Unidad 1, con $\hat{p}$ en lugar de $\hat{y}$

	Log-loss	Brier
Rango	$[0, \infty)$	$[0, 1]$
Penalización	logarítmica	cuadrática
Error confiado ($\hat{p}=0.01, y=1$)	4.61	0.98
Error confiado ($\hat{p}=0.001, y=1$)	6.91	≈ 1.00
Conecta con	deviance, pseudo- R^2	ECM, R^2

Ambas son **proper scoring rules**: su valor esperado se minimiza exactamente cuando $\hat{p} = p$ verdadera. Por eso premian reportar la probabilidad correcta, no la más extrema.

Accuracy no lo es: si p verdadera = 0.7, reportar $\hat{p} = 1$ mejora la accuracy esperada.

¿Qué reportar? Depende del uso

Tres preguntas distintas, tres familias de métricas. Ninguna sustituye a las otras.

Calibración

¿Las probabilidades son correctas?

Log-loss · Brier
Gráfico de calibración

Discriminación

¿Ordena bien los casos?

ROC-AUC
Resolución

Decisión

¿La regla que voy a aplicar funciona?

Matriz de confusión
Accuracy · F1

Regla práctica: estimar y seleccionar modelos siempre con pérdidas propias (log-loss, Brier); reportar el desempeño de la regla de decisión final con la matriz de confusión, en el umbral que realmente se va a usar.

Accuracy y F1 son métricas de reporte, no de optimización.