Laboratorio de datos: web scraping y Procesamiento de Lenguaje Natural

Clase 7. Embeddings y clasificación de texto

factor-data
EIDAES_UNSAM

Hipótesis distribucional

- “El significado deriva del uso de las palabras en el lenguaje” (Wittgenstein)

- “Conocerás a una palabra por su compañía” (Firth)

- Palabras cercanas tienen sentidos “cercanos”
- Ítems lingüísticos con distribuciones similares tienen significados similares”
- Idea de co-ocurrencia => términos que ocurren juntos

Clasificación de texto

Clasificación de texto

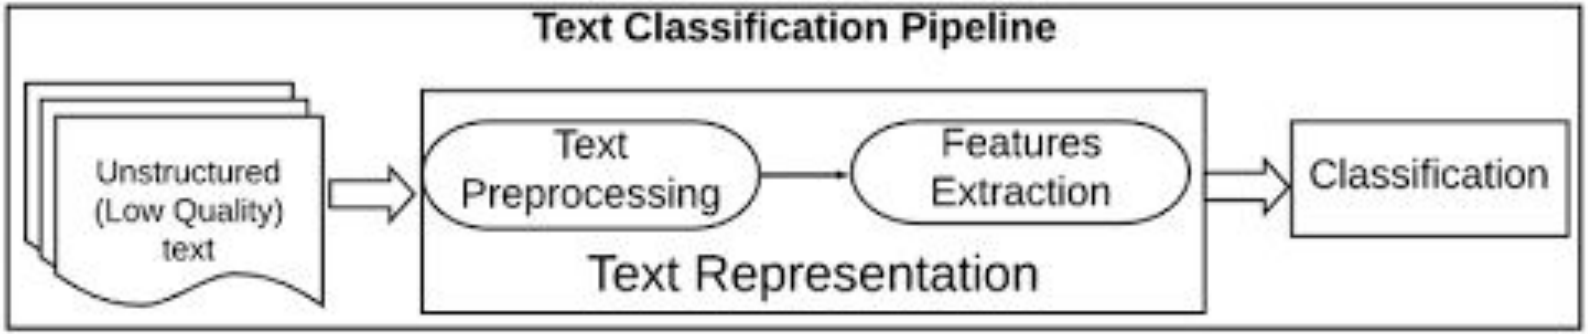

Clasificación de texto

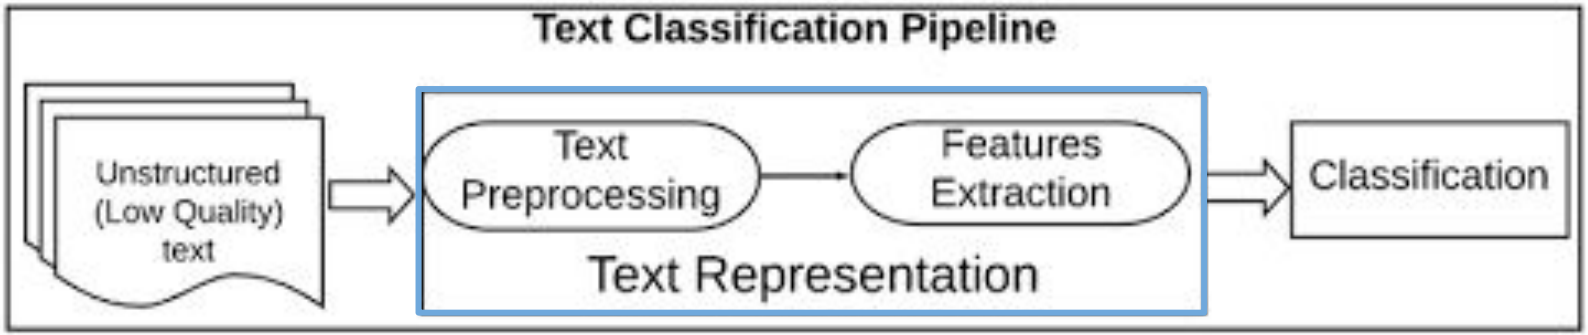

- Dos formas (que vimos):
  - Bag of Words => Term Frequency Matrix
  - Word Embeddings => Dense word Matrix

Clasificación de texto

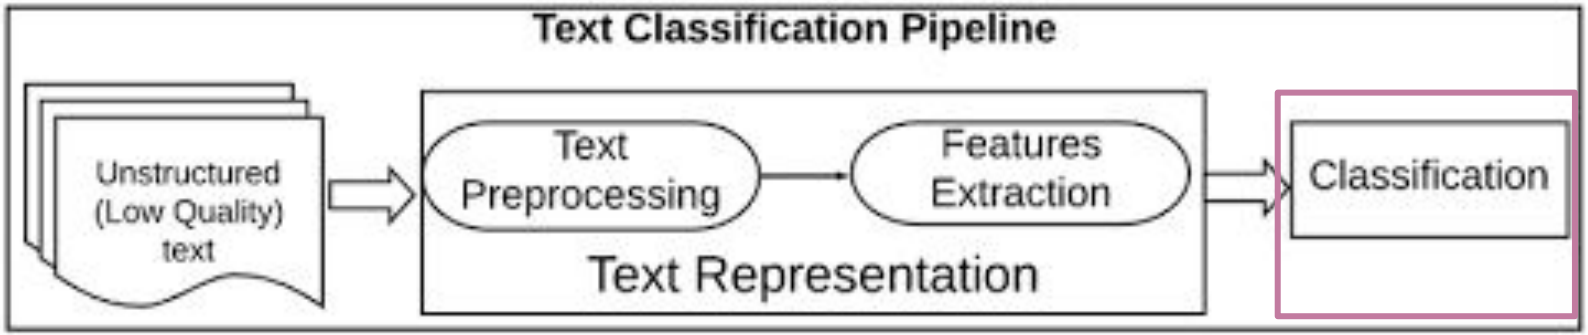

- Cualquiera de los métodos supervisados que vimos:
  - Regresión (¿lineal o logística?)
  - Random Forest
  - Gradient Boosting …

- O que no vimos… RNN, LSTM, Transformers, etc…

Vamos al notebook...

Algunas cuestiones para cerrar…

- NLP “Del giro linguístico al giro (lingüístico) computacional”.
- Posibilidades metodológicas para las ciencias sociales
- Discusiones “no metodológicas” que suscitan

  Innatismo o no del lenguaje (discusión con Chomsky)

  “Los límites de mi mundo son los de mi lenguaje”.